

Systeme Intelligent Multi-Modèles pour la Maintenance Prédictive Industrielle

Rapport d'Industrialisation et de Data Science

Module : Data Science & Full-Stack Industrialization

Enseignante : Sarah Malaeb

Année Universitaire : 2025-2026

Auteurs : Randriamahaleo & Shanthakumar

Statut : Livrable Final

1. Introduction et Cadre Théorique

Dans l'industrie moderne 4.0, l'intégration des technologies numériques et de l'intelligence artificielle est devenue un levier stratégique majeur pour optimiser l'efficacité opérationnelle et maximiser la disponibilité des actifs de production. Traditionnellement, les politiques de maintenance se divisaient en deux approches : la maintenance corrective (intervenir après la panne, entraînant des coûts élevés d'arrêt de production) et la maintenance préventive systématique (intervenir à intervalles fixes, entraînant des remplacements prématurés de pièces encore fonctionnelles).

La **maintenance prédictive industrielle** s'impose comme une alternative disruptive en s'appuyant sur l'apprentissage automatique (Machine Learning) supervisé. L'objectif est d'apprendre automatiquement une fonction de prédiction à partir de données historiques d'entrée collectées par des capteurs (vibrations, températures, pressions, régimes moteurs) afin d'anticiper les dégradations physiques avant qu'elles ne mènent à une rupture catastrophique de l'outil industriel.

1.1 formulation de la Tâche Prédictive

Dans le cadre de ce projet, notre choix s'est porté sur une approche de **classification binaire**. La variable cible à prédire est définie par la métrique *failure_within_24h* (0 si aucune panne n'est détectée dans les prochaines 24 heures, 1 si une anomalie critique va se produire). Cette formulation permet à l'exploitant de l'usine de disposer d'un horizon décisionnel de 24 heures pour planifier une coupure technique contrôlée, commander les pièces détachées requises et assigner l'équipe technique appropriée, réduisant ainsi drastiquement les coûts de réparation imprévus.

Rôle du modèle au sein du système global :

Le modèle de Data Science développé ici ne reste pas confiné à un notebook de recherche. Il sert de noyau décisionnel à une architecture logicielle découplée, matérialisée par une API REST robuste (FastAPI) et un tableau de bord interactif (Streamlit) permettant le suivi en temps réel des flottes industrielles par les équipes de maintenance.

2. Analyse Exploratoire des Données (EDA)

Le jeu de données fourni est constitué de **24 042** observations et de **15** variables initiales contenant des informations temporelles, des indicateurs de fonctionnement des machines, ainsi que des données financières et opérationnelles. L'analyse descriptive a mis en lumière plusieurs caractéristiques fondamentales du signal industriel.

2.1 Analyse Statistique et Constats Clés

- **Déséquilibre des classes** : Sur les 24 042 lignes, la classe minoritaire (panne sous 24h) représente environ 14,8 % du jeu de données (ratio de déséquilibre de 5.8:1). Ce fort déséquilibre est représentatif de la réalité industrielle (les pannes sont heureusement plus rares que le fonctionnement normal) mais nécessite une attention particulière lors de la phase de modélisation pour éviter que les modèles ne sur-optimisent la classe majoritaire au détriment de la détection des pannes.
- **Données manquantes** : Des absences de données ont été observées sur plusieurs fonctionnalités de capteurs clés : *vibration_rms* (1000 valeurs manquantes), *temperature_motor* (834), *current_phase_avg* (731), *pressure_level* (924) et *rpm* (533). Ces manques sont généralement dus à des coupures de transmission ou des défaillances de capteurs secondaires.

3. Nettoyage des Données et Preprocessing

Le passage de données brutes à des variables d'apprentissage exploitables est une étape critique garantissant la validité et la robustesse des prédictions futures. Notre pipeline de preprocessing a été construit de manière rigoureuse afin de respecter strictement les contraintes opérationnelles et statistiques.

3.1 Élimination des Fuites de Données (Data Leakage)

Une analyse critique des variables initiales a révélé la présence de plusieurs colonnes introduisant un biais majeur si elles étaient incluses dans l'entraînement. Nous avons procédé à l'exclusion systématique des variables suivantes :

- *rul_hours* (Remaining Useful Life) : Cette variable indique explicitement le nombre d'heures restantes avant la panne, ce qui est l'exact équivalent de la variable cible et fausserait totalement l'évaluation en conditions réelles.
- *estimated_repair_cost* et *failure_type* : Ces informations ne sont connues et calculées qu'**après** la survenue effective de la panne. Leur intégration constituerait une fuite d'information anachronique.
- *machine_id* et *timestamp* : Identifiants techniques n'apportant aucune valeur de généralisation statistique pour la prédiction globale.

En conséquence, nous avons retenu un ensemble final de **7 caractéristiques d'entrée** purement prédictives : *[vibration_rms, temperature_motor, current_phase_avg, pressure_level, rpm, hours_since_maintenance, ambient_temp]*.

3.2 Stratégie d'Imputation et de Division des Données

Pour traiter les valeurs manquantes sans introduire de biais de projection, nous avons appliqué une stratégie d'**imputation par la médiane** via un *SimpleImputer* de Scikit-Learn. Très important : l'ajustement du template d'imputation (*.fit()*) a été réalisé uniquement sur l'ensemble d'entraînement (*X_train*), puis appliqué par

transformation simple (`.transform()`) sur l'ensemble de test (`X_test`). Cela prévient toute fuite d'information statistique du bloc de test vers le bloc d'entraînement.

Le jeu de données a été scindé selon une distribution **stratifiée** (70 % entraînement, 30 % test), préservant le ratio exact de 14,8 % de pannes dans les deux sous-ensembles :

- `X_train` : 16 829 observations
- `X_test` : 7 213 observations

3.3 Gestion du Déséquilibre des Classes

Afin de contrebalancer le ratio de 5.8:1, deux approches distinctes ont été testées et comparées :

1. L'utilisation de la pondération native des algorithmes via le paramètre `class_weight='balanced'`, rééquilibrant mathématiquement la fonction de coût lors de la rétropropagation de l'erreur.
2. L'application de la méthode **SMOTE** (Synthetic Minority Over-sampling Technique) qui génère des observations synthétiques pour la classe minoritaire dans l'espace des caractéristiques afin d'atteindre une parité parfaite (14 337 exemples par classe dans l'ensemble d'entraînement).

4. Architecture des Modèles Comparés

Conformément aux exigences méthodologiques de notre cursus, nous avons implémenté et évalué trois types d'architectures de complexités croissantes afin d'établir un benchmark robuste.

- **Modèle 1 : Régression Logistique (Baseline)**

Modèle linéaire servant de référence. Rapide, transparent, mais limité dans sa capacité à modéliser des interactions complexes non-linéaires entre les capteurs industriels.

- **Modèle 2 : Forêt Aléatoire (Random Forest)**

Méthode d'ensemble par bagging combinant de multiples arbres de décision entraînés en parallèle sur des sous-ensembles de données. Elle réduit nativement la variance et s'avère extrêmement robuste face aux valeurs aberrantes et aux fortes dimensionalités.

- **Modèle 3 : Gradient Boosting (XGB/GBM)**

Méthode d'ensemble par boosting construisant des arbres de décision de manière séquentielle. Chaque nouvel arbre est optimisé pour corriger spécifiquement les résidus et erreurs commis par ses prédécesseurs.

5. Résultats et Évaluation Comparative

Pour valider l'adéquation opérationnelle de nos modèles, l'évaluation s'est concentrée sur des métriques adaptées au déséquilibre : le **Rappel (Recall)** (capacité à capter toutes les pannes), la **Précision** (éviter les fausses alertes coûteuses), et le **F1-score** (la moyenne harmonique des deux).

Tableau 1 : Comparaison des performances (Sans SMOTE, avec pondération équilibrée)

Nom du Modèle	Exactitude (Accuracy)	Précision	Rappel (Recall)	F1-Score	ROC-AUC
Régression Logistique (Baseline)	0.8885	0.5840	0.8596	0.6955	0.9399
Random Forest (Retenu)	0.9597	0.8246	0.9242	0.8715	0.9916
Gradient Boosting	0.9566	0.8764	0.8230	0.8489	0.9856

Tableau 2 : Comparaison des performances (Avec Sur-échantillonnage SMOTE)

Nom du Modèle + SMOTE	Exactitude (Accuracy)	Précision	Rappel (Recall)	F1-Score	ROC-AUC
Régression Logistique + SMOTE	0.8913	0.5922	0.8539	0.6994	0.9398
Random Forest + SMOTE	0.9583	0.8100	0.9382	0.8694	0.9907
Gradient Boosting + SMOTE	0.9387	0.7271	0.9382	0.8193	0.9851

6. Pourquoi le Random Forest est-il le meilleur modèle ?

À la lumière des résultats numériques, le modèle **Random Forest (sans SMOTE, avec `class_weight='balanced'`)** a été sélectionné comme le modèle de production final pour le système intelligent de maintenance prédictive. Cette décision repose sur une triple justification technique et économique :

- Supériorité du F1-Score global (0.8715) :** En contexte de maintenance industrielle, un modèle ne peut pas se contenter d'avoir une bonne exactitude globale (l'exactitude peut être trompeuse en raison du déséquilibre). Le Random Forest atteint le meilleur compromis opérationnel avec une Précision de 82,46 % et un Rappel exceptionnel de 92,42 %.
- Priorité économique au Rappel (Recall) :** Une panne non détectée (Faux Négatif) engendre des coûts catastrophiques (arrêt de chaîne, casse mécanique, pénalités de retard). Avec un Rappel de **92,42 %**, le

Random Forest ne laisse échapper que très peu d'anomalies (seulement 81 pannes manquées sur 1 068 réelles selon la matrice de confusion), surpassant nettement le Gradient Boosting standard (82,30 %). Bien que l'application de SMOTE augmente légèrement le rappel à 93,82 %, elle dégrade la précision à 81,00 % et introduit une latence de calcul artificielle inutile.

3. **Stabilité et Pouvoir de Discrimination (ROC-AUC de 0.9916)** : Ce score presque parfait indique que la capacité du modèle à ordonner les risques de panne et à séparer les états sains des états dégradés est d'une fiabilité absolue, indépendamment du seuil de classification choisi.

7. Interprétabilité Globale et Locale (SHAP)

Un aspect crucial pour l'adoption des solutions d'intelligence artificielle par les ingénieurs de terrain est l'explicabilité des modèles ("boîte noire"). Nous avons intégré la technologie **SHAP (SHapley Additive exPlanations)** basée sur la théorie des jeux coopératifs pour analyser la contribution de chaque fonctionnalité.

L'analyse globale (Beeswarm plot) révèle que l'indicateur *vibration_rms* est la caractéristique la plus déterminante, suivie immédiatement par *temperature_motor* et *hours_since_maintenance*. Physiquement, une augmentation des vibrations RMS est le signe avant-coureur d'un désalignement ou d'une usure des roulements, validant l'alignement des apprentissages du modèle avec les lois de la mécanique industrielle.

Au niveau local, l'explication de prédictions spécifiques (comme l'observation 16 du jeu de données, signalant une panne imminente) permet d'afficher dans l'interface Streamlit les causes exactes de l'alerte (par exemple : une température moteur anormale combinée à un nombre élevé d'heures d'exploitation depuis la dernière révision).

8. Architecture d'Industrialisation et Livrables

Afin de matérialiser la transition vers le **Bloc 2**, l'ensemble des artefacts issus de l'entraînement a été sérialisé et exporté selon un contrat d'interface strict :

- *model.pkl* : Pipeline sérialisé contenant l'imputeur et le classifieur entraîné, prêt à l'emploi.
- *metrics.json* : Métriques de performance validées pour le suivi de la dérive du modèle (Data Drift).
- *feature_importance.json* : Importance des variables calculée par permutation pour alimenter les graphiques du Dashboard.

8.1 Conclusion et Perspectives

Ce projet démontre l'efficacité des approches d'apprentissage d'ensemble pour la fiabilisation des outils de production. Les étapes suivantes consisteront à intégrer ces artefacts au sein de notre API FastAPI pour

permettre des prédictions en temps réel avec un temps de réponse inférieur à 50ms, et de connecter le Dashboard Streamlit pour offrir une vue holistique aux opérateurs de l'usine.

Fin du Rapport Technique — EFREI Paris — Randriamahaleo & Shanthakumar